

Grundlagen KI und Maschinelles Lernen

Ugurtan Can Cetin, Patrick Furtwängler, Niclas Gugel,
Marvin Obert, Mikhail Sen



Prüfungsaufgabe 1

- a) Programmieren Sie eine Python-Funktion für das Ranking von Art Stories im Word2vec Embedding, die einer Anfrage durch einen Besucher Ihrer Kunst-Website am ähnlichsten sind.
- b) Beurteilen Sie den Einfluss der Erweiterung auf das Doc2Vec Embedding auf die Ergebnisqualität.
- c) Programmieren Sie einen Empfehlungsdienst für Art Stories durch Clustering mit Top2Vec.

Prüfungsaufgabe 1 - a

```
def rank_art_stories_python_function(user_query_string):
    user_query_words = text_to_word_list(user_query_string)
    user_query_vector = {}
    for word in allWordsRanking:
        user_query_vector[word] = user_query_words.count(word)
    dataframe_blueprint = {
        "Query": [],
        "Title": [],
        "Cosine Similarity": [],
        "Euclidian Distance": [],
        "Similarity Value": [],
    }

    dataframe = pd.DataFrame(dataframe_blueprint)
    alpha = 1e-10 # 1 * 10^-10 = 0.0000000001
    for vector in vectors:
        similarity = cosine_similarity([list(user_query_vector.values())], [list(vector.values())])[0][0]
        distance = euclidean_distances([list(user_query_vector.values())], [list(vector.values())])[0][0]
        dict = {"Query": user_query_string, "Title": titles[vectors.index(vector)], "Cosine Similarity": similarity,
                "Euclidian Distance": distance, "Similarity Value": similarity + 1 / (distance + alpha)}
        dataframe = dataframe.append(dict, ignore_index = True)
    return dataframe.sort_values(by="Similarity Value", ascending=False)
```

	Query	Title	Cosine Similarity	Euclidian Distance	Similarity Value
0	Paris	My Paris: Patrick Roger, master chocolatier	0.289430	13.564660	0.363151
1	Paris	Beyond the waves: Alex Ayed's journey	0.159561	37.456642	0.186258
2	Paris	Painter Sean Landers unleashes his critters in Paris	0.043806	68.447060	0.058416
4	Paris	Hans Ulrich Obrist remembers Agnès Varda	0.019309	103.561576	0.028966
3	Paris	Artist-led initiatives are transforming Accra into a world-class cultural hub	0.000000	114.686529	0.008719

Prüfungsaufgabe 1 - b

```
def doc2Vec_model(user_query_string):

    # Read the given documents into array. Here the bag of words from earlier won't be used, and we will make sure to use the convenience of provided methods.
    documents = []
    with open('./Aufgabe 1/art_stories_examples.csv', 'r', encoding="utf-8") as file:
        for line in file.readlines()[1:]:
            lineSecs = line.split(";")
            documents.append(clean_text(lineSecs[1]) + clean_text(lineSecs[2]) + clean_text(lineSecs[3]))

    # Tokenize and tag the documents
    tagged_data = [TaggedDocument(words=word_tokenize(_d.lower()), tags=[str(i)]) for i, _d in enumerate(documents)]

    # Create instance of Doc2Vec and provide tagged data to train it
    model = Doc2Vec(vector_size=20, min_count=1, epochs=100)
    model.build_vocab(tagged_data)
    model.train(tagged_data, total_examples=model.corpus_count, epochs=model.epochs)

    # Create Vector for user query, with infer_vector method, because the words in the user query can not assure if they are in the vocabulary
    user_vector = model.infer_vector(word_tokenize(user_query_string.lower()))

    # Go through every document and generate Ranking. The ranking will be a list of tuples, where the first value is the document and the second value is the rank.
    ranks = []
    for i in range(len(documents)):
        doc_vector = model.docvecs[str(i)]
        rank = cosine_similarity([user_vector.tolist()], [doc_vector.tolist()])[0][0]
        ranks.append((documents[i], rank))

    # Sort by rank
    ranks.sort(key=lambda x: x[1])

    return ranks
```

Prüfungsaufgabe 1 - c

```
def recommend_art_stories_python_function(identifier_of_visited_art_stories_list):
    """Based of the created clusters of the top2vec we search in
    which cluster the visited art stories where assigned and therefore
    recommend the top 3 similar documents (top 1 of each cluster)"""

    # Read the documents into a dataframe with pandas
    dataframe = pd.read_csv('./Aufgabe 1/art_stories_examples.csv', delimiter=';')

    # create the document for the Top2Vec clustering
    documents = dataframe['Text'].tolist()
    # in this case we multiply the amount of documents by 10. The library we use needs enough documents to train the model with
    # this changes the value in this case, but because we didnt have a big enough dataset, this is what we used.
    # when testing and having a big enough data set please comment the line
    documents = documents * 10

    # Here we give Top2Vec our documents, and it will create a model out of every document.
    # We use the universal-sentence-encoder, because those are pretrained and it will run faster.
    # there is another model 'doc2vec' but that would take longer to generate
    top2vec_model = Top2Vec(documents, embedding_model='universal-sentence-encoder', min_count=1, speed='fast-learn', workers=4)

    # after the model is trained, we will get the topic for each document.
    # this method wont only return the topic. it will return a list of items in this order:
    # a list of numbers which represent the topic numbers of the document
    # a list of scores, which represent the similarity of the document to the topics
    # for each topic the top 50 words
    # a list of word scores for each topic and document, which is represented by cosine similarity
    visited_vector_topics = top2vec_model.get_documents_topics(identifier_of_visited_art_stories_list)

    # get the list of topic indices
    visited_topic_indices = visited_vector_topics[0]

    recommendation = []
    # go through every topic
    for visited_topic_index in visited_topic_indices:
        # get the most similar document in the topic
        similar_documents_based_on_topic = top2vec_model.search_documents_by_topic(visited_topic_index, num_docs=1)
        # add the document, which is the most similar in the topic to the recommendations
        recommendation.append(similar_documents_based_on_topic[0])
    return recommendation
```

Prüfungsaufgabe 2

Empfehlung von Kunstwerken mit Matrix-Faktorisierung im Content- und Collaborative Filtering und Kundenprofilanreicherung

- a) Übertragen Sie die Tracking Daten (Sample_Tracking_Data_for_Recommender_System_ABCD.csv) in das User-Item Interaction Matrix Template (User-Item_Interaction_Matrix_Template_With_Randomized_Values.csv).
 - Tipp: Definieren Sie den zeitlichen Rahmen für die Verweildauer auf einem Kunstwerk so, dass diese als implizites Feedback interpretiert werden kann.
 - Tipp: Um bessere Ergebnisse zu erzielen, können z.B. weitere Tracking-Profile aus synthetischen Daten erzeugt werden.
- b) Optimieren Sie relevante Parameter (z.B. von bm25_weight, AlternatingLeastSquares) in der Code-Vorlage so, dass beim Aufruf der Funktionen user_recommend() und artwork_recommend() sinnvolle Empfehlungen von Kunstwerken ausgesprochen werden. Begründen Sie jeweils Ihre Entscheidungen.
- c) Implementieren Sie ein Python-Programm zur textbasierten Anreicherung der Kundenprofile (s. Spalte BESCHREIBUNG) in einem Customer Relationship Management System einschl. einfachem Flask Web-App User Interface.

Prüfungsaufgabe 3

Erstellung eines Wissensgraphen für Kunst (Aufgabe 1) und Abfrage mithilfe natürlicher Sprache (Aufgabe 2)

- 1 Optimieren Sie das Python-Programm `Art.Knowledge.Graph.py` auf die Verwendung mit dem Datensatz `Art.Stories.csv` (s. Moodle) für die Erzeugung eines sinnvollen Wissensgraphen.
- 2 Implementieren Sie eine Python-Funktion zur SPARQL-Abfrage des Wissensgraphen aus *Aufgabe 1* mithilfe natürlicher

Sprache. Gehen Sie hierzu wie folgt vor:

- a) Analysieren Sie den generellen Aufbau des Programmcodes `QAsparql`.
 - Aktualisierter Code s. Moodle (Aus: <https://github.com/Sylvia-Liang/QAsparql>)
 - Aus: Querying knowledge graphs in natural language, Liang et. al, ETH Zürich, Springer Open, Journal of Big Data.
 - **Evtl. hilfreiche Installationshinweise:**
 - `python -m spacy download en_core_web_lg`
 - `pip install fasttext-wheel`
 - GloVe-Download nach `QAsparql-master\learning\treelstm\data\glove:` <https://github.com/stanfordnlp/GloVe?tab=readme-ov-file> (z.B. Wikipedia 2014 + Gigaword 5)
- b) Implementieren Sie eine Python-Funktion zur Extraktion von RDF-Tripeln (z.B. als *.ttl-File*, vgl. *dbpedia 3Eng class.ttl*) aus Ihrem in *Aufgabe 1* erzeugten Wissensgraphen.
- c) Erstellen Sie für die 3 im Paper erwähnten Fragetypen List, Count und Boolean jeweils Beispiel-Trainingsdaten
Hinweis: Die Beispiele können analog zu den Trainingsdaten in `QAsparql-master\data/LC-QUAD/train-data.json` aufgebaut sein.
- d) Implementieren Sie eine Python-Funktion, die eine Anfrage in natürlicher Sprache in die entsprechende SPARQL-Query basierend auf Ihren in c) generierten Beispiel-Trainingsdaten übersetzt:
 - **Funktionsname:**
`natural_language_to_sparql_query(natural_language_query_string)`
 - **return:** `sparql_query_for_knowledge_graph_string`


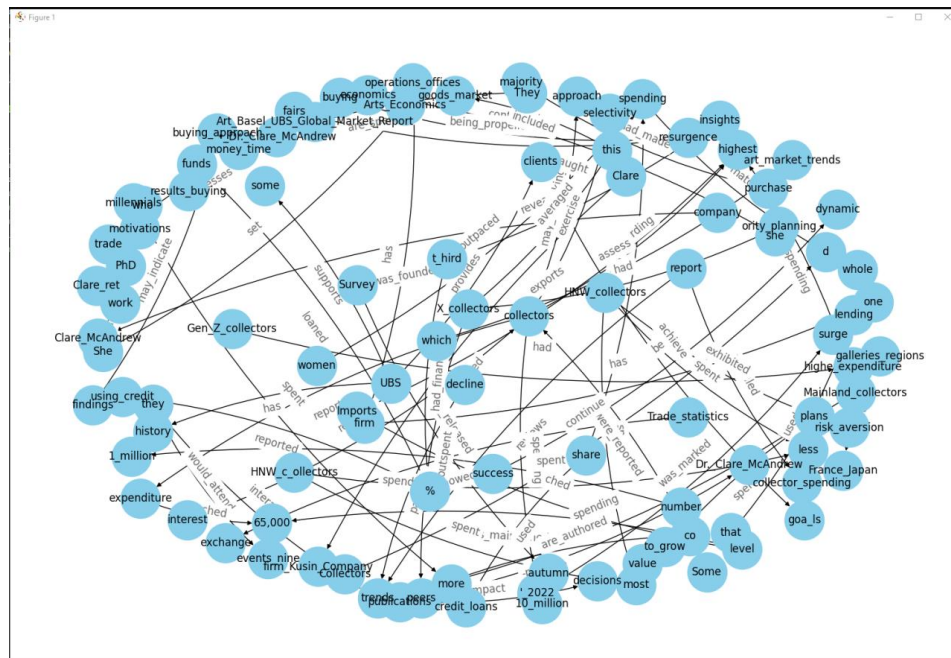
Prüfungsaufgabe 3 - 1

```
def __init__(self, path, isPDF = False, topic="Art Basel Fair") -> None:
    dataSource = None
    text = ""
    if(isPDF):
        pdfFileObj = open(path, 'rb')
        pdfReader = PyPDF2.PdfReader(pdfFileObj)
        for page in pdfReader.pages:
            text += page.extract_text()
        pdfFileObj.close()
    else:
        textDataFrame = pd.read_csv(path, sep=",")
        textDataFrame['STORY_TEXT'] = textDataFrame['STORY_TEXT'].apply(self.clean_text_from_html_content)
        for id, line in textDataFrame.iterrows():
            text += line[1]
```

```
def clean_text_from_html_content(self, string):
    text = re.sub('<.*?>', ' ', string)
    soup = BeautifulSoup(text, 'html.parser')
    text = soup.get_text()
    text = re.sub(r'\s+', ' ', text)
    re.sub(r"[^\w\s\.\!\\?\\(\\)]", "", text)

    with open(self.filepath, "w", encoding="utf-8") as t_file:
        t_file.write(text)
        t_file.close()
    return text
```


Prüfungsaufgabe 3 - 1





Prüfungsaufgabe 3 – 2 a

Prüfungsaufgabe 3 – 2 b

```
# This method will take the generated graph and save it as a .ttl file
# For the convenience of the devs (us :) ), a library called RDFLib is used
# the graph is generated using the networkx library
def generate_ttl_file(self, GRAPH, output_file="output.ttl"):
    graph = rdflib.Graph()

    for edge in GRAPH.edges(data=True):
        subj = rdflib.URIRef(edge[0])
        pred = rdflib.URIRef(edge[2]['relation'])
        obj = rdflib.URIRef(edge[1])
        graph.add((subj, pred, obj))
    graph.serialize(destination=output_file, format="turtle")
```

```
<Andrée> <chose> <Quarantina_area> .

<Franck> <has_honored> <legacy> .

<I> <do> <what> ;
    <have> <to_say> ;
    <would_not_consider> <buying> .

<Meet_Antenna_Space_Get> <to_know> <Simon_Wang> .

<Simon_Wang_he> <saw> <city> .

<You> <had> <feeling> ;
    <have> <beauty_next>,
    <reasons> .

<father> <was_fascinated> <art> .

<it> <provided> <her> .

<we> <had> <visitors> .

<Simon_Wang> <opened> <Shanghai_gallery> .

<what> <makes> <work> .
```

Prüfungsaufgabe 3 – 2 c

```
{
  "_id": "66",
  "corrected_question": "Is the Mona Lisa housed in the Louvre Museum?",
  "intermediary_question": "Is the <Louvre Museum> the <housing location> of the <Mona Lisa>?",
  "sparql_query": "ASK WHERE { http://dbpedia.org/resource/Mona\_Lisa http://dbpedia.org/property/housedIn http://dbpedia.org/resource/Louvre\_Museum }",
  "sparql_template_id": 153
},
{
  "_id": "67",
  "corrected_question": "Did Alexander Graham Bell invent the telephone?",
  "intermediary_question": "Is <Alexander Graham Bell> the <inventor> of the <telephone>?",
  "sparql_query": "ASK WHERE { http://dbpedia.org/resource/Alexander\_Graham\_Bell http://dbpedia.org/property/inventor http://dbpedia.org/resource/Telephone }",
  "sparql_template_id": 154
},
{
  "_id": "68",
  "corrected_question": "Is Mount Everest the tallest mountain in the world?",
  "intermediary_question": "Is <Mount Everest> the <tallest mountain> in the <world>?",
  "sparql_query": "ASK WHERE { http://dbpedia.org/resource/Mount\_Everest http://dbpedia.org/property/tallestMountainIn http://dbpedia.org/resource/World }",
  "sparql_template_id": 155
},
}
```

Prüfungsaufgabe 3 – 2 c

```
{
  "_id": "2701",
  "corrected_question": "Who directed the movie 'Inception'?",
  "intermediary_question": "Who directed the movie '<Inception>'?",
  "sparql_query": "SELECT DISTINCT ?director WHERE {<http://dbpedia.org/resource/Inception> <http://dbpedia.org/ontology/director> ?director}",
  "sparql_template_id": 315
},
{
  "_id": "2702",
  "corrected_question": "List the prime ministers of the United Kingdom.",
  "intermediary_question": "List the prime ministers of the <United Kingdom>.",
  "sparql_query": "SELECT DISTINCT ?primeMinister WHERE {<http://dbpedia.org/resource/United_Kingdom> <http://dbpedia.org/ontology/leaderName> ?primeMinister}",
  "sparql_template_id": 316
},
```

Prüfungsaufgabe 3 – 2 c

```
{
  "_id": "66",
  "corrected_question": "Is the Mona Lisa housed in the Louvre Museum?",
  "intermediary_question": "Is the <Louvre Museum> the <housing location> of the <Mona Lisa>?",
  "sparql_query": "ASK WHERE { http://dbpedia.org/resource/Mona\_Lisa http://dbpedia.org/property/housedIn http://dbpedia.org/resource/Louvre\_Museum }",
  "sparql_template_id": 153
},
{
  "_id": "67",
  "corrected_question": "Did Alexander Graham Bell invent the telephone?",
  "intermediary_question": "Is <Alexander Graham Bell> the <inventor> of the <telephone>?",
  "sparql_query": "ASK WHERE { http://dbpedia.org/resource/Alexander\_Graham\_Bell http://dbpedia.org/property/inventor http://dbpedia.org/resource/Telephone }",
  "sparql_template_id": 154
},
{
  "_id": "68",
  "corrected_question": "Is Mount Everest the tallest mountain in the world?",
  "intermediary_question": "Is <Mount Everest> the <tallest mountain> in the <world>?",
  "sparql_query": "ASK WHERE { http://dbpedia.org/resource/Mount\_Everest http://dbpedia.org/property/tallestMountainIn http://dbpedia.org/resource/World }",
  "sparql_template_id": 155
},
}
```



Prüfungsaufgabe 3 – 2 d

Prüfungsaufgabe 4

Entwicklung eines Kunst-Chatbots

- ① Erstellen Sie repräsentative Anfragen (*engl. Prompts*) an einen Kunst-Chatbot während einer Kunstmesse mit den entsprechenden User Stories in tabellarischer Form aus Sicht von

- Kunst-Sammler (z.B. Privatier, Museum) und
- Kunst-Aussteller (z.B. Galerie, Künstler).

Prompt	As a <role>	I want <goal>	so that <benefit>	Acceptance criteria (Conditions of satisfaction)
...

- ② Optimieren Sie den Kunst-Chatbot im Programmcode `Chatbot_LangChain_RAG.py` auf die beiden Metriken
- Sensibleness und Specifity Average (SSA) und
 - Perplexität.
- ③ Identifizieren Sie zusätzliche Optimierungspotentiale des Kunst-Chatbots und beurteilen diese im Hinblick auf den Einsatz bei einer realen Kunstmesse.

Prüfungsaufgabe 5

Aufgabenteil 1: Messung der Ähnlichkeit von Künstlern

- a) Beschreiben Sie die im Programmcode *artists_similarity_cnn.py* beschriebene Vorgehensweise zur Messung der Ähnlichkeit von Künstlern.
- b) Clustern Sie Künstler in sinnvolle Gruppen.
Tip: Verwenden Sie hierfür die Projektion der Künstler in das Koordinatensystem aus dem Diagramm „*Artists Projected on First Two PCs.*“
- c) Beurteilen Sie die Aussagekraft der im Programmcode beschriebenen Ähnlichkeitsmessung von Künstlern.

Aufgabenteil 2: Generierung von Bildbeschreibungen


- Passen Sie die Parameter im Programm *Image_Caption_Generator_Transformer.py* so an, dass sinnvolle textbasierte Bildbeschreibungen (*engl.: image captions*) für Kunstwerke erzeugt werden.
Hinweis: Sinnvoll bedeutet insb., dass die Bildbeschreibungen potentiell für weitere Anwendungsfälle wie z.B. textbasiertes Clustern eingesetzt werden können.
-

Prüfungsaufgabe 5 - 1


Average Colour by Artist



Artists Projected on First Two PCs, Explained Variance: 83%



Prüfungsaufgabe 5



```
def dbscan_cluster(primary_components):  
    dbscan = DBSCAN(eps=2, min_samples=1)  
    clusters = dbscan.fit_predict(primary_components)  
    return clusters
```

- Unbekannte Clusteranzahl
- Aufgrund ähnlicher Eigenschaften von Epochen schwer linear zu trennen

Prüfungsaufgabe 6

- ① Trainieren Sie die Q-Tabelle für die in der Übersicht dargestellte Momentaufnahme mithilfe der Belohnungsmatrix (Reward_Matrix_Show_Snapshot.xlsx) und geben ein Beispiel für einen idealen Pfad an.
- ② Programmieren Sie eine Python-Funktion, die für einen gegebenen Zustand innerhalb der drei Serviceanfrage-Phasen während des Messeverlaufs die optimale Strategie zurückgibt:
 - `def optimal_strategy_function(current_timestep, current_phase_number, current_state_number, current_reward_matrix_dataframe)`
 - `current_timestep`: Integer increment
 - `current_phase_number` in [1,2,3]
 - `current_state_number` in [0,...,30]
 - `current_reward_matrix_dataframe` als 31x31 Dataframe
 - `return updated_timestep, updated_phase_number, next_state_number, updated_reward_matrix_dataframe`
- ③ Erstellen Sie eine einfache Visualisierung der resultierenden Bewegungsabläufe des Roboters in der Maze-Darstellung für jeweils eine Beispiel-Sequenz in den drei Phasen.
- ④ Beurteilen Sie, inwiefern der Einsatz von Dataset Aggregation zur Effizienzsteigerung Ihres Roboters bei einer realen Kunstmesse beitragen kann.

Prüfungsaufgabe 6 - 1

```
def read_xlsx_into_two_dimensional_list(self, file_path):
    result = []
    workbook = openpyxl.load_workbook(file_path)
    sheet = workbook.active
    for row in sheet.iter_rows(values_only=True):
        result.append(list(row))
    result = [inner[2:] for inner in result[2:]]
    return result
```

```
elif i == 7:
    possible_keys = dict[i].keys()
    if 12 in possible_keys:
        q_table[i]["L"] = dict[i][12]
        state_table[i]["L"] = 12
    if 13 in possible_keys:
        q_table[i]["R"] = dict[i][13]
        state_table[i]["R"] = 13
    if 0 in possible_keys:
        q_table[i]["U"] = dict[i][0]
        state_table[i]["U"] = 0
    if 24 in possible_keys:
        q_table[i]["D"] = dict[i][24]
        state_table[i]["D"] = 24
    continue
```

```
def create_q_table_and_state_table(self, reward_matrix):
    dict = {}

    for i, inner_list in enumerate(reward_matrix):
        dict[i] = {}
        for j, value in enumerate(inner_list):
            if value != -1:
                dict[i][j] = value
    q_table = {}
    state_table = {}

    for i in dict.keys():
        q_table[i] = {}
        state_table[i] = {}
        for j in dict[i].keys():
            if i == 12: ...
            elif i == 20: ...
            elif i == 7: ...
            elif i == 11: ...
            if j-1 == i:
                q_table[i]["R"] = dict[i][j]
                state_table[i]["R"] = j
            elif j+1 == i:
                q_table[i]["L"] = dict[i][j]
                state_table[i]["L"] = j
            elif j+1 < i:
                q_table[i]["U"] = dict[i][j]
                state_table[i]["U"] = j
            elif j-1 > i:
                q_table[i]["D"] = dict[i][j]
                state_table[i]["D"] = j

    return q_table, state_table
```

```
> 0: {'R': 0, 'D': 5}
> 1: {'L': 5, 'R': 0, 'D': 5}
> 2: {'L': 0, 'R': 0}
> 3: {'L': 0, 'R': 0, 'D': 0}
> 4: {'L': 0, 'R': 0}
> 5: {'L': 0, 'R': 5, 'D': 0}
> 6: {'L': 0, 'D': 5}
> 7: {'L': 1, 'R': 0, 'U': 5, 'D': 5}
> 8: {'U': 0, 'D': 0}
> 9: {'U': 0, 'D': 0}
> 10: {'U': 0, 'D': 0}
```

```
> 0: {'R': 1, 'D': 7}
> 1: {'L': 0, 'R': 2, 'D': 8}
> 2: {'L': 1, 'R': 3}
> 3: {'L': 2, 'R': 4, 'D': 9}
> 4: {'L': 3, 'R': 5}
> 5: {'L': 4, 'R': 6, 'D': 10}
> 6: {'L': 5, 'D': 11}
> 7: {'L': 12, 'R': 13, 'U': 0, 'D': 24}
> 8: {'U': 1, 'D': 14}
> 9: {'U': 3, 'D': 16}
> 10: {'U': 5, 'D': 18}
```

Prüfungsaufgabe 6 - 2

- ① Es sind keine Serviceanfragen vorhanden. Hinweise:
- Verwenden Sie die Strategie aus Aufgabe 1 (vgl. Exploitation Prinzip) in Verbindung mit einer zufälligen Komponente bei der Auswahl der nächsten Aktion (Exploration).
 - Die Dauer der Phase 1 beträgt 100 Zeitschritte (z.B. Minuten)

```
# Phase 1
if current_phase_number == 1:
    if current_timestep < 100:
        current_timestep += 1
        random_action = self.create_random_action()
        while not self.is_action_valid(current_state_number, random_action):
            random_action = self.create_random_action()
        state_after_action = self.state_table[current_state_number][random_action]

        return current_timestep, 1, state_after_action, self.reward_matrix
    return current_timestep, 2, current_state_number, self.reward_matrix
```

Prüfungsaufgabe 6 - 2

- ② Die zu Beginn vorhandenen Serviceanfragen (vgl. Reward_Matrix_Show_Snapshot.xlsx) werden sukzessive abgearbeitet, bis alles erledigt ist. Hinweise:
- Nachdem eine Dienstleistung durch den Roboter erbracht wurde, wird die entsprechende Belohnung in der Belohnungsmatrix auf -1 zurückgesetzt und die Q-Tabelle aus Aufgabe 1 wird neu berechnet.
 - Die Dauer der Phase 2 hängt von der Anzahl Serviceanfragen ab.

```
elif current_phase_number == 2:
    current_timestep += 1
    best_action, best_reward = self.get_best_action_from_q_table(new_state_number)

    if self.is_action_valid(new_state_number, best_action):
        old_state = new_state_number
        new_state_number = self.state_table[new_state_number][best_action]
        new_reward_matrix = self.remove_reward_from_matrix(old_state)
        self.q_table, self.state_table = self.create_q_table_and_state_table(new_reward_matrix)


    # go to new service state, when there are no service_tasks left
    if self.count_service_tasks(new_reward_matrix) == 0:
        return 0, 3, current_state_number, self.reward_matrix
    return current_timestep, 2, current_state_number, self.reward_matrix
```

Prüfungsaufgabe 6 - 2

- ③ Es sind immer Serviceanfragen vorhanden und neue treffen zufällig ein:
- Vorgehen analog zu Phase 2 durch jeweiliges Aktualisieren der Belohnungsmatrix und Neuberechnen der Q-Tabelle.
 - Die Dauer der Phase 3 beträgt 10 Zeitschritte

```
# Phase 3
else:
    current_timestep += 1
    self.create_random_service_task()
    best_action, best_reward = self.get_next_best_action(current_state_number)
    if self.is_action_valid(current_state_number, best_action):
        new_state_number = self.state_table[current_state_number][best_action]
        new_reward_matrix = self.remove_reward_from_matrix(current_state_number)
        self.q_table, self.state_table = self.create_q_table_and_state_table(new_reward_matrix)
    if current_timestep > 25:
        return 0, 1, current_state_number, self.reward_matrix
    return current_timestep, 3, current_state_number, self.reward_matrix
```


Prüfungsaufgabe 6 - 3



```
def redraw_everything(self, currentStateID, currentPathList, font, text, textRect):
    self.screen.fill((255, 255, 255))
    self.screen.blit(self.floor, (0, 0))
    self.screen.blit(self.robot, self.get_plot_position(currentPathList[currentStateID]))
    text = font.render("Moves: " + str(currentStateID) + " / " + str(len(currentPathList)-1), True, (255, 0, 0))
    self.screen.blit(text, textRect)

def plot(self, pathLists):
    self.floor = pygame.transform.scale(self.floor, (1250, 500))
    self.robot = pygame.transform.scale(self.robot, (50, 50))

    self.screen.blit(self.floor, (0, 0))
    self.screen.blit(self.robot, self.get_plot_position(12))

    stateID = 0

    for pathList in pathLists:
        font = pygame.font.Font(None, 36)
        text = font.render("Moves: " + str(stateID) + " / " + str(len(pathList)-1), True, (255, 0, 0))
        textRect = text.get_rect()
        self.screen.blit(text, textRect)
        print(pathList)
        while self.running:
            for i in pygame.event.get():
                if i.type == pygame.QUIT:
                    self.running = False
                elif i.type == pygame.KEYDOWN:
                    if i.key == pygame.K_ESCAPE:
                        self.running = False
                    elif i.key == pygame.K_RIGHT:
                        stateID = stateID + 1 if stateID < len(pathList)-1 else stateID
                    elif i.key == pygame.K_LEFT:
                        stateID = stateID - 1 if stateID > 0 else stateID
                    self.redraw_everything(stateID, pathList, font, text, textRect)
            pygame.display.update()
```